Outputs Appendix: Run Evidence for the Tanglish RAG Retrieval Study

Selvin PaulRaj K · M.E – Computer Science Engineering · Kings Engineering College, Chennai · 210825405017@kingsedu.ac.in

This appendix collects the actual outputs of the Module 2 code: dataset statistics, the Tanglish normaliser's before/after output, top-k retrieval results for example queries, the result tables and charts, latency, and the console logs of a re-run done for this review. The full experiment (84 runs, 180,936 ranked lists) ran on 31 October 2026 on a 2-core ARM64 CPU without a GPU. On 2 November 2026 the demo script `scripts/09_demo_outputs.py` re-ran retrieval from the cached multilingual-e5-small embeddings and reproduced the reported MRR@10 values exactly (Section O8).

O1. Dataset statistics

Property	Value
Source	nlpctx/tamil-english-retrieval (Hugging Face, Apache-2.0)
Documents (seed 42 sample)	500 Tamil news documents + English translations
Queries per form	2,154 (one gold document each; about 4.3 per document)
Query sets	English, Tamil script, romanised, code-mixed + ITRANS and rules versions of romanised and code-mixed (8)
Document length (Tamil chars)	mean 390.9, median 326, max 2,795
Runs	40 (Tamil corpus) + 20 (English corpus) + 24 naive-fusion reruns = 84; 180,936 ranked lists

Query composition (2,154 queries per set)

Query set	Avg tokens	Latin tokens %	Latin judged English %	Tamil tokens in corpus vocab %
English	5.6	98.9	85.1	–
Tamil script	5.0	0.3	40.5	77.7
Romanised	5.1	98.9	14.2	0.0
Code-mixed	5.7	98.9	69.0	–
Rom → ITRANS	5.1	14.0	100.0	15.2
Rom → rules	5.1	13.8	100.0	29.9
CM → ITRANS	5.7	68.2	100.0	16.6
CM → rules	5.7	68.2	100.0	24.9

Code-mix audit

Measure	Value
Code-mixed queries identical to English	13.3%
Code-mixed queries with no Tamil token	22.0%
Mean Tamil tokens per code-mixed query	1.74
Mean Tamil tokens per romanised query	4.3

O2. Tanglish normaliser: queries before and after

Twelve romanised queries drawn at random (seed 7) from the 2,154, with the output of the ITRANS baseline and of the Tanglish rules, against the dataset's own Tamil-script version of the same question. English tokens (names, frequent English words) are kept by the language-ID step.

qid	Romanised (input)	ITRANS output	Tanglish rules output	Dataset Tamil-script query
q01077	moolakootru vaaippaattaik kurikkum adaiyaala chinnangal	மூலகூத்ரு வாஇப்பாத்தைக் குரிக்கும் அதையால சிந்நந்கல்	மூலகூற்று வாஇப்பாட்டைக் குரிக்கும் அடையால சின்னங்கல்	மூலக்கூற்று வாய்ப்பாட்டைக் குறிக்கும் அடையாளச் சின்னங்கள்
q00279	Senbagavalli anai udaippu vivarangal	ஸேந்பகவல்லி அநை உதைப்பு விவரந்கல்	சென்பகவல்லி அனை உடைப்பு விவரங்கல்	செண்பகவல்லி அணை உடைப்பு விவரங்கள்
q01476	Guru Peyarchi kaalathil kuzhandhai baakkiyam	Guru பேயர்சி காலதில் குழந்தை பாக்கியம்	Guru பெயர்சி காலதில் குழந்தை பாக்கியம்	குருபெயர்ச்சி காலத்தில் குழந்தை பாக்கியம்
q01136	Janavari 3 vivasayi maaradaippu seithi	ஜநவரி 3 விவஸயி மாரதைப்பு ஸேஇதி	ஜனவரி 3 விவசயி மாரடைப்பு செஇதி	ஜனவரி 3 விவசாயி மாரடைப்பு செய்தி
q00217	Osho Rajneesh tharkkam matrum thathuvam	ஓஶோ ரஜ்நீஶ் தர்க்கம் மத்ரும் ததுவம்	ஒஷொ ரஜ்னீஷ் தர்க்கம் மற்றும் ததுவம்	ஓஷோ ரஜினீஷ் தர்க்கம் மற்றும் தத்துவம்
q02152	chithi matrum magal idaiyeyana uravu sikkalhal	சிதி மத்ரும் மகல் இதையேயந உரவு ஸிக்கல்ஹல்	சிதி மற்றும் மகல் இடையெயன உரவு சிக்கல்ஹல்	சித்தி மற்றும் மகள் இடையேயான உறவு சிக்கல்கள்
q01133	Tamilnattil vivasayigal maaradaippal irappargal	தமில்நத்தில் விவஸயிகல் மாரதைப்பல் இரப்பர்கல்	டமில்னட்டில் விவசயிகல் மாரடைப்பல் இரப்பர்கல்	தமிழ்நாட்டில் விவசாயிகள் மாரடைப்பால் இறப்பார்கள்
q01665	thirumanam thaamadamaavadharkaana jothida kaaranangal	திருமநம் தாமதமாவதர்காந ஜோதித காரநந்கல்	திருமனம் தாமடமாவதர்கான ஜொதிட காரனங்கல்	திருமணம் தாமதமாவதற்கான ஜோதிட காரணங்கள்
q02083	enpathukalin sirantha tamil kaathal thiraipadangal	ஏந்பதுகலிந் ஸிரந்த tamil காதல் திரைபதந்கல்	என்பதுகலின் சிரந்த tamil காதல் திரைபடங்கல்	எண்பதுகளின் சிறந்த தமிழ் காதல் திரைப்படங்கள்
q00885	koirikkaigalin munnetrathai kankanippadhan nanmaigal	கோஇரிக்கைகலிந் முந்நேத்ரதை கந்கநிப்பதந் நந்மைகல்	கொஇரிக்கைகலின் முன்னெற்றதை கன்கனிப்பதன் நன்மைகல்	கோரிக்கைகளின் முன்னேற்றத்தைக் கண்காணிப்பதன் நன்மைகள்
q01623	1962 John Glenn vinveniyil seluthum paadhaiyai kanakkittavar	1962 John Glenn விந்வேநியில் ஸேலுதும் பாதையை கநக்கித்தவர்	1962 John Glenn வின்வெனியில் செலுதும் பாதையை கனக்கிட்டவர்	1962 ஜான் க்ளெனை விண்வெளியில் செலுத்தும் பாதையை கணக்கிட்டவர்
q01478	Guru Peyarchi etruvadhi irakkumadhi thozhil	Guru பேயர்சி ஏத்ருவதி இரக்குமதி தோழில்	Guru பெயர்சி எற்றுவதி இரக்குமதி தொழில்	குருபெயர்ச்சி ஏற்றுமதி இறக்குமதி தொழில்

O3. Top-5 retrieval for example queries (Tamil corpus)

For each information need, the query in every form is sent to the dense retriever (multilingual-e5-small) and to character 3-gram BM25. Numbers are corpus document indices; ★ marks the gold document. Rank = position of the gold document in the top 10 (– = not retrieved).

Example 1 (q01571) · gold document #365

கொலம்பியா நாட்டின் அராவ்கா துறைக்கு உட்பட்ட அராகிட்டா நகராட்சி பகுதியில் ராணுவ வீரர்கள் மீ…
English translation: A guerrilla attack on military personnel in the municipality of Aragita, in the Arawka region of Colombia, has killed 5 soldiers…

Form	Query given to the retriever	Dense top-5	Rank	Char-3 top-5	Rank	Dense top-1 document
English	Colombia military soldiers killed in attack	★**365** 446 424 127 326	1	189 151 310 357 48	–	✓ கொலம்பியா நாட்டின் அராவ்கா துறைக்க…
Tamil script	தாக்குதலில் கொலம்பியா ராணுவ வீரர்கள் உயிரிழப்பு	★**365** 162 18 446 127	1	★**365** 135 451 162 460	1	✓ கொலம்பியா நாட்டின் அராவ்கா துறைக்க…
Romanised	thakkudhalil Colombia raanuva thiraigal uyirizhappu	426 483 69 288 212	–	151 273 283 443 426	–	✗ பஞ்சாலை தொழிலாளர்களின் வாழ்வியலையு…
Rom. + ITRANS	தக்குதலில் Colombia ராநுவ திரைகல் உயிரிழப்பு	★**365** 162 399 212 483	1	★**365** 451 89 135 195	1	✓ கொலம்பியா நாட்டின் அராவ்கா துறைக்க…
Rom. + rules	தக்குதலில் Colombia ரானுவ திரைகல் உயிரிழப்பு	★**365** 162 399 483 212	1	★**365** 451 89 135 162	1	✓ கொலம்பியா நாட்டின் அராவ்கா துறைக்க…
Code-mixed	Colombia military soldiers killed in attack	★**365** 446 424 127 326	1	189 151 310 357 48	–	✓ கொலம்பியா நாட்டின் அராவ்கா துறைக்க…
CM + rules	Colombia military soldiers killed in attack	★**365** 446 424 127 326	1	189 151 310 357 48	–	✓ கொலம்பியா நாட்டின் அராவ்கா துறைக்க…

Example 2 (q00660) · gold document #152

வடக்கு மாகாண பாடசாலை மாணவிகளின் சீருடையின் நீளத்தை அதிகரிக்க வேண்டும் என்று வடக்கு மாகாண உ…
English translation: A member of the Northern Province ஜி.ரி.லிங்கநாதன் has demanded that the length of the uniform of the schoolgirls of the Northern Province be increased. A sessi…

Form	Query given to the retriever	Dense top-5	Rank	Char-3 top-5	Rank	Dense top-1 document
English	Northern Province school uniform length request	★**152** 398 129 309 285	1	272 273 269 137 20	–	✓ வடக்கு மாகாண பாடசாலை மாணவிகளின் சீ…
Tamil script	வடக்கு மாகாண பாடசாலை சீருடை நீளம் கோரிக்கை	★**152** 398 468 105 426	1	★**152** 398 368 449 416	1	✓ வடக்கு மாகாண பாடசாலை மாணவிகளின் சீ…
Romanised	Vadakku maagaana paadasaalai seerudai neelam korikkai	69 483 73 426 396	–	404 24 310 341 221	–	✗ "பின்னே என்ன சார்? ஒருத்தரை வெறுக்…
Rom. + ITRANS	வதக்கு மாகாந பாதஸாலை ஸீருதை நீலம் கோரிக்கை	194 73 69 403 426	–	★**152** 208 451 368 71	1	✗ எந்தக் கட்சி ஆட்சியில் இருந்தாலும்…
Rom. + rules	வடக்கு மாகான பாடசாலை சீருடை நீலம் கொரிக்கை	★**152** 396 99 69 86	1	★**152** 398 368 416 133	1	✓ வடக்கு மாகாண பாடசாலை மாணவிகளின் சீ…
Code-mixed	Northern province school uniform length increase request	★**152** 398 129 285 309	1	272 273 269 151 426	–	✓ வடக்கு மாகாண பாடசாலை மாணவிகளின் சீ…
CM + rules	Northern province school uniform length increase request	★**152** 398 129 285 309	1	272 273 269 151 426	–	✓ வடக்கு மாகாண பாடசாலை மாணவிகளின் சீ…

Example 3 (q00114) · gold document #27

புதுடில்லி : 'முத்தலாக்' தடை மசோதா, ராஜ்யசபாவில் இன்று(டிச.,31) தாக்கல் செய்யப்படுகிறது. இ…
English translation: New Delhi: The Triple Talaq (Prohibition) Bill is being introduced in the Rajya Sabha today (December 31), following which the BJP-Congress parties have been as…

Form	Query given to the retriever	Dense top-5	Rank	Char-3 top-5	Rank	Dense top-1 document
English	Triple Talaq Bill Rajya Sabha introduction	386 74 ★**27** 426 483	3	273 272 310 233 443	–	✗ மேற்கண்ட தகவல்கள் 2006 ஜூன் மல்லிக…
Tamil script	முத்தலாக் தடை மசோதா ராஜ்யசபா	★**27** 194 69 351 426	1	★**27** 119 303 409 268	1	✓ புதுடில்லி : 'முத்தலாக்' தடை மசோதா…

Form	Query given to the retriever	Dense top-5	Rank	Char-3 top-5	Rank	Dense top-1 document
Romanised	Muthalaq thadai masoda Rajyasabha	73 69 92 483 403	–	404 341	–	✗ அழகிய மணிமுடியும், தாமரை மலர் போல ...
Rom. + ITRANS	முதலஃ'க் ததை மஸோத ரஜ்யஸப	73 69 403 110 329	–	★27 306 268 50 108	1	✗ அழகிய மணிமுடியும், தாமரை மலர் போல ...
Rom. + rules	முதலக் ததை மசொட ரஜ்யசப	194 92 322 69 62	–	★27 119 268 307 28	1	✗ எந்தக் கட்சி ஆட்சியில் இருந்தாலும்...
Code-mixed	Triple Talaq bill Rajya Sabha la eppo	194 426 386 ★27 296	4	310 426 243 273 350	–	✗ எந்தக் கட்சி ஆட்சியில் இருந்தாலும்...
CM + rules	Triple டலக் bill ரஜ்ய Sabha ல எப்பொ	194 296 386 426 69	–	441 119 310 331 461	–	✗ எந்தக் கட்சி ஆட்சியில் இருந்தாலும்...

Example 4 (q00000) · gold document #0

உத்தரப்பிரதேசத்தின் கோரக்பூரில், 1893 ஜனவரி 5-ஆம் தேதி, வங்காள க்ஷத்ரியக் குடும்பத்தில் பி...
English translation: Born in Gorakhpur, Uttar Pradesh, on 5 January 1893, to a Bengali Kshatriya family, his parents named him Mukundlal Ghosh. Growing up devoutly at a young age, M...

Form	Query given to the retriever	Dense top-5	Rank	Char-3 top-5	Rank	Dense top-1 document
English	Who is Mukundlal Ghosh	★0 10 69 483 426	1	273 283 443	–	✓ உத்தரப்பிரதேசத்தின் கோரக்பூரில், 1...
Tamil script	முகுந்தலால் கோஷ் யார்	★0 69 278 483 403	1	★0 278 431 68 262	1	✓ உத்தரப்பிரதேசத்தின் கோரக்பூரில், 1...
Romanised	Mukundlal Ghosh yaar	69 73 92 194 255	–	478 273 283 443	–	✗ "பின்னே என்ன சார்? ஒருத்தரை வெறுக்...
Rom. + ITRANS	முகுந்த்லல் கோஷ் யார்	★0 69 302 483 278	1	★0 431 278 68 258	1	✓ உத்தரப்பிரதேசத்தின் கோரக்பூரில், 1...
Rom. + rules	முகுண்ட்லல் கொஷ் யார்	★0 278 483 403 69	1	419 431 ★0 68 278	3	✓ உத்தரப்பிரதேசத்தின் கோரக்பூரில், 1...
Code-mixed	Mukundlal Ghosh na yaaru	69 73 194 92 483	–	273 283 443	–	✗ "பின்னே என்ன சார்? ஒருத்தரை வெறுக்...
CM + rules	முகுண்ட்லல் கொஷ் ந யாரு	483 69 213 403 ★0	5	419 ★0 179 431 378	2	✗ எதிர்வரும் காலங்களில் சர்வதேச கடற்...

O4. Result tables (from results/main_results.csv and significance.csv)

MRR@10, Tamil corpus, all 8 query sets × 7 retrievers

Query set	BM25	Char-3	Dense	RRF	RRF3	RRF naive	RRF3 naive
Tamil script	0.811	0.923	0.903	0.895	0.911	0.884	0.911
English	0.067	0.062	0.788	0.710	0.305	0.187	0.151
Code-mixed	0.069	0.063	0.687	0.637	0.278	0.181	0.149
Romanised	0.056	0.058	0.143	0.178	0.113	0.092	0.088
Rom. + ITRANS	0.210	0.547	0.328	0.386	0.506	0.261	0.439
Rom. + rules	0.333	0.684	0.535	0.537	0.627	0.441	0.582
CM + ITRANS	0.093	0.197	0.666	0.585	0.412	0.196	0.303
CM + rules	0.111	0.238	0.692	0.568	0.420	0.212	0.325

Recall@10, Tamil corpus

Query set	BM25	Char-3	Dense	RRF	RRF3
Tamil script	0.891	0.964	0.974	0.960	0.970
English	0.078	0.088	0.937	0.936	0.879
Code-mixed	0.079	0.088	0.862	0.863	0.801
Romanised	0.068	0.082	0.294	0.321	0.262
Rom. + ITRANS	0.290	0.705	0.518	0.592	0.718
Rom. + rules	0.449	0.812	0.746	0.742	0.842
CM + ITRANS	0.116	0.322	0.859	0.855	0.703
CM + rules	0.135	0.369	0.880	0.841	0.704

MRR@10, English-translation corpus

Query set	BM25	Char-3	Dense	RRF	RRF3	RRF naive	RRF3 naive
English	0.870	0.876	0.939	0.920	0.916	0.917	0.916
Tamil script	0.064	0.050	0.742	0.728	0.113	0.192	0.145
Code-mixed	0.865	0.855	0.875	0.900	0.901	0.894	0.901
Romanised	0.522	0.445	0.333	0.544	0.557	0.493	0.548

Paired significance tests (2,000 resamples; query and document-cluster bootstrap)

Comparison	Retrievers	Before	After	Change	p (query)	p (cluster)	Change 95% CI (cluster)
Rom. → Rom.+rules	Dense-e5 → Dense-e5	0.143	0.535	+0.391	<0.001	<0.001	[+0.365, +0.417]
Rom. → Rom.+rules	BM25-char3 → BM25-char3	0.058	0.684	+0.626	<0.001	<0.001	[+0.596, +0.655]
Rom. → Rom.+rules	Hybrid-RRF3 → Hybrid-RRF3	0.113	0.627	+0.514	<0.001	<0.001	[+0.485, +0.542]
Rom.+ITRANS → Rom. +rules	Dense-e5 → Dense-e5	0.328	0.535	+0.207	<0.001	<0.001	[+0.184, +0.230]
Rom.+ITRANS → Rom. +rules	BM25-char3 → BM25-char3	0.547	0.684	+0.137	<0.001	<0.001	[+0.113, +0.161]
CM → CM+rules	Dense-e5 → Dense-e5	0.687	0.692	+0.005	0.446	0.573	[-0.013, +0.022]
CM → CM+rules	BM25 → BM25	0.069	0.111	+0.042	<0.001	<0.001	[+0.024, +0.062]
CM → CM+rules	Hybrid-RRF3 → Hybrid-RRF3	0.278	0.420	+0.142	<0.001	<0.001	[+0.115, +0.167]
Tamil → Tamil	Dense-e5 → Hybrid-RRF	0.903	0.895	-0.008	0.168	0.287	[-0.023, +0.007]
Tamil → Tamil	Dense-e5 → Hybrid-RRF-naive	0.903	0.884	-0.019	0.003	0.032	[-0.036, -0.002]
English → English	Dense-e5 → Hybrid-RRF	0.788	0.710	-0.079	<0.001	<0.001	[-0.090, -0.068]
English → English	Dense-e5 → Hybrid-RRF-naive	0.788	0.187	-0.601	<0.001	<0.001	[-0.634, -0.567]
CM → CM	Dense-e5 → Hybrid-RRF	0.687	0.637	-0.050	<0.001	<0.001	[-0.062, -0.038]
CM → CM	Dense-e5 → Hybrid-RRF-naive	0.687	0.181	-0.506	<0.001	<0.001	[-0.540, -0.471]
Rom. → Rom.	Dense-e5 → Hybrid-RRF	0.143	0.178	+0.034	<0.001	<0.001	[+0.023, +0.046]
Rom. → Rom.	Dense-e5 → Hybrid-RRF-naive	0.143	0.092	-0.052	<0.001	<0.001	[-0.075, -0.030]
Rom.+rules → Rom.+rules	Dense-e5 → Hybrid-RRF	0.535	0.537	+0.002	0.803	0.856	[-0.023, +0.026]
Rom.+rules → Rom.+rules	Dense-e5 → Hybrid-RRF-naive	0.535	0.441	-0.094	<0.001	<0.001	[-0.126, -0.062]

Comparison	Retrievers	Before	After	Change	p (query)	p (cluster)	Change 95% CI (cluster)
Rom.+rules → Rom.+rules	BM25-char3 → Hybrid-RRF3	0.684	0.627	-0.057	<0.001	<0.001	[-0.080, -0.034]

O5. Charts

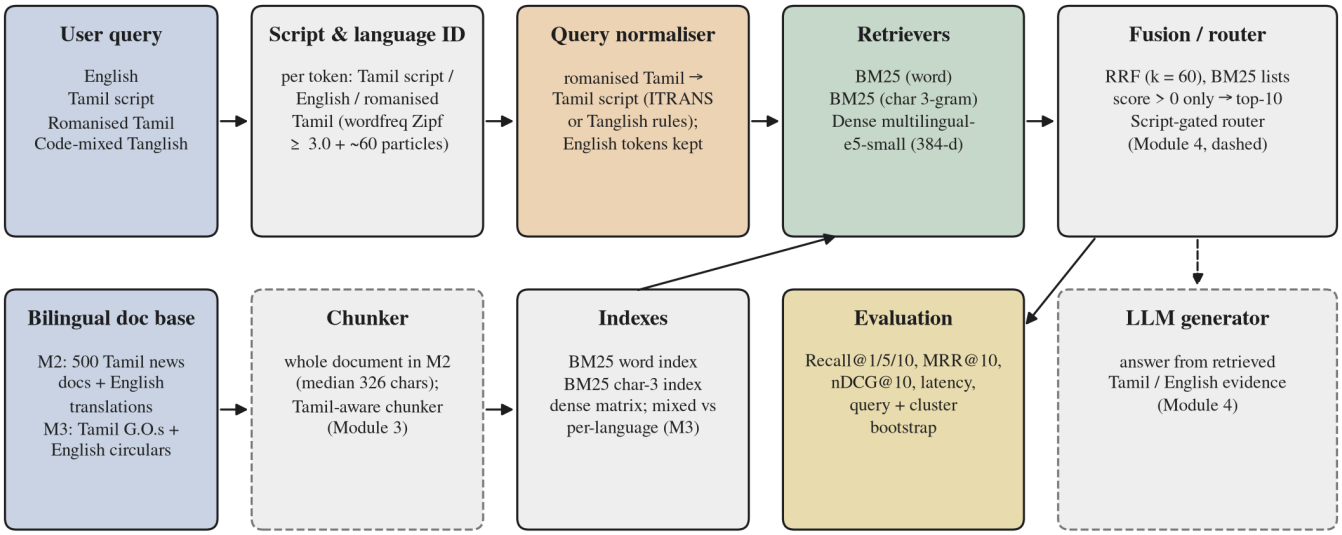


Figure O1. Proposed architecture over a bilingual Tamil–English document base (dashed = later modules).

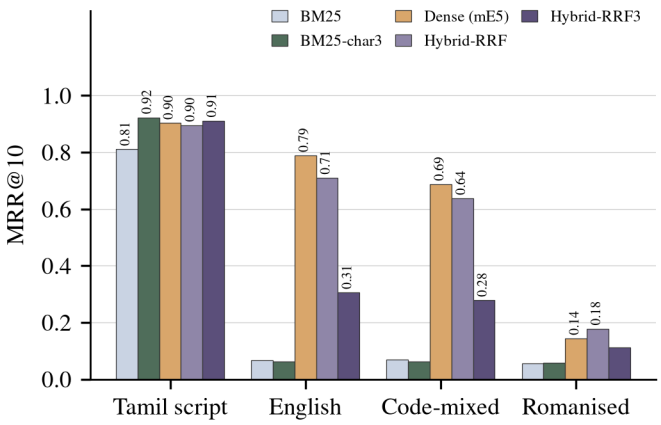


Figure O2. MRR@10 by raw query form and retriever (Tamil corpus).

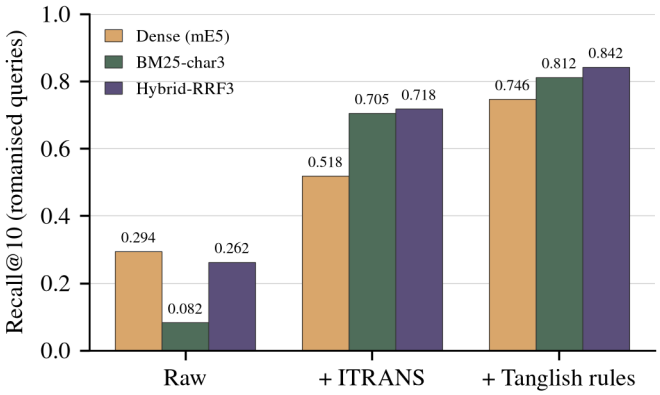


Figure O3. Recall@10 of romanised queries: raw, ITRANS, Tanglish rules.

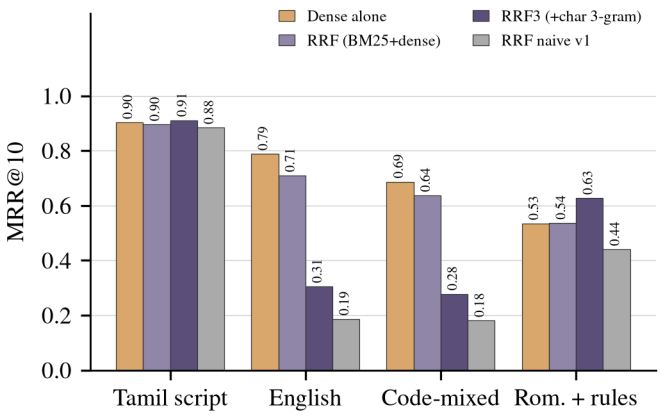


Figure O4. Dense alone vs corrected RRF / RRF3 and the naive v1 fusion.

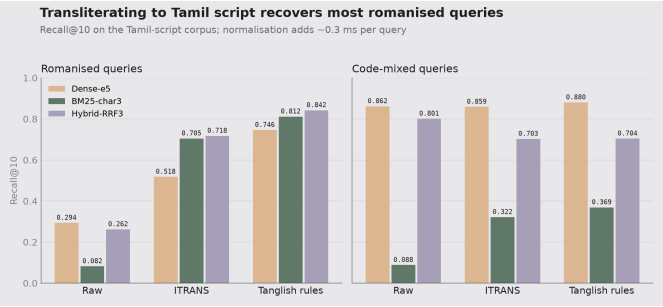


Figure O5. Original Module 2 chart: Recall@10 for romanised and code-mixed queries, raw vs normalised.

O6. Latency

Single query, one at a time, 200 random romanised queries (2 CPU cores)

Stage	Median ms	p95 ms
normalise	0.335	0.481
bm25_word	0.671	0.984
bm25_char3	4.875	8.585
dense_encode	32.108	39.257
dense_search	0.136	0.180
rrf	0.187	0.229
Sum of medians (rules + RRF3)	**38.3**	

Mean search time per query inside the full evaluation run (ms)

Corpus	Query set	BM25 word	BM25 char-3	Dense search
en	Code-mixed	0.764	4.521	0.091
en	English	0.768	4.327	0.109
en	Romanised	0.688	4.838	0.089
en	Tamil script	0.679	4.341	0.105
ta	Code-mixed	0.68	4.284	0.088
ta	CM + ITRANS	0.694	4.334	0.089
ta	CM + rules	0.71	4.458	0.09
ta	English	0.707	4.204	0.092
ta	Romanised	0.616	4.667	0.103
ta	Rom. + ITRANS	0.684	5.209	0.097
ta	Rom. + rules	0.659	4.885	0.114
ta	Tamil script	0.646	5.18	0.102

O7. Console log: normaliser self-test

```
● ● ●   selvin@me-tanglish: ~/code

$ python src/tanglish_rag/normalise.py
Kizhaku maagana payitrapatta aasiriyar tharam 3 paritchai nilai
  rules : கிழகு மாகன பயிற்றபட்ட ஆசிரியர் தரம் 3 பரிட்சை நிலை
  itrans: கிழகு மாகந பயித்ரபத்த ஆஸிரியர் தரம் 3 பரித்சை நிலை
scholarship ku last date enna?
  rules : scholarship கு last date என்ன?
  itrans: scholarship கு last date ஏந்ந?
Israel Hamas conflict ku yaar responsible
  rules : Israel Hamas conflict கு யார் responsible
  itrans: Israel Hamas conflict கு யார் responsible
Annamalai palkalaikazhagam kurithu uyarkalvithurai amaichar Ponmudi
  rules : அன்னமலை பல்கலைகழகம் குரிது உயர்கல்விதுரை அமைசர் பொன்முடி
  itrans: அந்நமலை பல்கலைகழகம் குரிது உயர்கல்விதுரை அமைசர் போந்முதி
karbhinigal seyarkai kulirpanangal kudikkalama
  rules : கர்பினிகல் செயர்கை குலிர்பனங்கல் குடிக்கலம
  itrans: கர்பிநிகல் ஸேயர்கை குலிர்பநந்கல் குதிக்கலம
```

O8. Console log: demo and reproduction run (2 Nov 2026)

Section 4 of the log recomputes six headline MRR@10 values from scratch (cached embeddings + BM25 indexes rebuilt) and compares them with `results/main_results.csv`; all six match. The normaliser latency printed here (mean, warm language-ID cache) is lower than the 0.34 ms median in Table O6, which was timed per query inside the latency script.

```
● ● ●   selvin@me-tanglish: ~/code

$ python scripts/09_demo_outputs.py

================================================================================
1. DATASET
================================================================================
documents (Tamil corpus)     : 500
queries per form             : 2154
query sets                   : en, ta, rom, cm, rom_itrans, rom_rules, cm_itrans, cm_rules
doc length chars mean/median/max : 390.9 / 326 / 2795
queries per document (mean)  : 4.31

================================================================================
2. TANGLISH NORMALISER (romanised Tamil -> Tamil script; English tokens kept)
================================================================================

  input  : scholarship ku last date enna?
  rules  : scholarship கு last date என்ன?
  ITRANS : scholarship கு last date ஏந்ந?

  input  : Israel Hamas conflict ku yaar responsible
  rules  : Israel Hamas conflict கு யார் responsible
  ITRANS : Israel Hamas conflict கு யார் responsible

  input  : Vadakku maagaana paadasaalai seerudai neelam korikkai
  rules  : வடக்கு மாகான பாடசாலை சீருடை நீலம் கொரிக்கை
  ITRANS : வதக்கு மாகாந பாதஸாலை ஸீருதை நீலம் கோரிக்கை

  input  : thakkudhalil Colombia raanuva thiraigal uyirizhappu
  rules  : தக்குதலில் Colombia ரானுவ திரைகல் உயிரிழப்பு
  ITRANS : தக்குதலில் Colombia ராநுவ திரைகல் உயிரிழப்பு

  input  : Muthalaq thadai masoda Rajyasabha
  rules  : முதலக் தடை மசொட ரஜ்யசப
  ITRANS : முதலஃ'க் ததை மஸோத ரஜ்யஸப

  rules normalisation latency: 0.096 ms/query (mean over 200 romanised queries, warm cache)

================================================================================
3. TOP-5 RETRIEVAL FOR EXAMPLE QUERIES (Tamil corpus)
================================================================================

--- q01571   gold doc #365: கொலம்பியா நாட்டின் அராவ்கா துறைக்கு உட்பட்ட அராகிட்டா நகராட்சி பகுதியி...
  [en       ] Colombia military soldiers killed in attack
```

```
      dense top-5 : *365 446 424 127 326             gold rank 1   top-1: கொலம்பியா நாட்டின் அராவ்கா துறைக்கு உட...
      char3 top-5 : 189 151 310 357 48               gold rank -
  [ta       ] தாக்குதலில் கொலம்பியா ராணுவ வீரர்கள் உயிரிழப்பு
      dense top-5 : *365 162 18 446 127              gold rank 1   top-1: கொலம்பியா நாட்டின் அராவ்கா துறைக்கு உட...
      char3 top-5 : *365 135 451 162 460             gold rank 1
  [rom      ] thakkudhalil Colombia raanuva thiraigal uyirizhappu
      dense top-5 : 426 483 69 288 212               gold rank -   top-1: பஞ்சாலை தொழிலாளர்களின் வாழ்வியலையும், ...
      char3 top-5 : 151 273 283 443 426              gold rank -
  [rom_rules] தக்குதலில் Colombia ரானுவ திரைகல் உயிரிழப்பு
      dense top-5 : *365 162 399 483 212             gold rank 1   top-1: கொலம்பியா நாட்டின் அராவ்கா துறைக்கு உட...
      char3 top-5 : *365 451 89 135 162              gold rank 1
  [cm       ] Colombia military soldiers killed in attack
      dense top-5 : *365 446 424 127 326             gold rank 1   top-1: கொலம்பியா நாட்டின் அராவ்கா துறைக்கு உட...
      char3 top-5 : 189 151 310 357 48               gold rank -
      (* = gold document; numbers are corpus document indices)

--- q00660   gold doc #152: வடக்கு மாகாண பாடசாலை மாணவிகளின் சீருடையின் நீளத்தை அதிகரிக்க வேண்டும் ...
  [en       ] Northern Province school uniform length request
      dense top-5 : *152 398 129 309 285             gold rank 1   top-1: வடக்கு மாகாண பாடசாலை மாணவிகளின் சீருடை...
      char3 top-5 : 272 273 269 137 20               gold rank -
  [ta       ] வடக்கு மாகாண பாடசாலை சீருடை நீளம் கோரிக்கை
      dense top-5 : *152 398 468 105 426             gold rank 1   top-1: வடக்கு மாகாண பாடசாலை மாணவிகளின் சீருடை...
      char3 top-5 : *152 398 368 449 416             gold rank 1
  [rom      ] Vadakku maagaana paadasaalai seerudai neelam korikkai
      dense top-5 : 69 483 73 426 396                gold rank -   top-1: "பின்னே என்ன சார்? ஒருத்தரை வெறுக்கிறோ...
      char3 top-5 : 404 24 310 341 221               gold rank -
  [rom_rules] வடக்கு மாகான பாடசாலை சீருடை நீலம் கொரிக்கை
      dense top-5 : *152 396 99 69 86                gold rank 1   top-1: வடக்கு மாகாண பாடசாலை மாணவிகளின் சீருடை...
      char3 top-5 : *152 398 368 416 133             gold rank 1
  [cm       ] Northern province school uniform length increase request
      dense top-5 : *152 398 129 285 309             gold rank 1   top-1: வடக்கு மாகாண பாடசாலை மாணவிகளின் சீருடை...
      char3 top-5 : 272 273 269 151 426              gold rank -
      (* = gold document; numbers are corpus document indices)

--- q00114   gold doc #27: புதுடில்லி : 'முத்தலாக்' தடை மசோதா, ராஜ்யசபாவில் இன்று(டிச.,31) தாக்கல...
  [en       ] Triple Talaq Bill Rajya Sabha introduction
      dense top-5 : 386 74 *27 426 483               gold rank 3   top-1: மேற்கண்ட தகவல்கள் 2006 ஜூன் மல்லிகையில...
      char3 top-5 : 273 272 310 233 443              gold rank -
  [ta       ] முத்தலாக் தடை மசோதா ராஜ்யசபா
      dense top-5 : *27 194 69 351 426               gold rank 1   top-1: புதுடில்லி : 'முத்தலாக்' தடை மசோதா, ரா...
      char3 top-5 : *27 119 303 409 268              gold rank 1
  [rom      ] Muthalaq thadai masoda Rajyasabha
      dense top-5 : 73 69 92 483 403                 gold rank -   top-1: அழகிய மணிமுடியும், தாமரை மலர் போல சிவந...
      char3 top-5 : 404 341                          gold rank -
  [rom_rules] முதலக் தடை மசொட ரஜ்யசப
      dense top-5 : 194 92 322 69 62                 gold rank -   top-1: எந்தக் கட்சி ஆட்சியில் இருந்தாலும், 'ந...
      char3 top-5 : *27 119 268 307 28               gold rank 1
  [cm       ] Triple Talaq bill Rajya Sabha la eppo
      dense top-5 : 194 426 386 *27 296              gold rank 4   top-1: எந்தக் கட்சி ஆட்சியில் இருந்தாலும், 'ந...
      char3 top-5 : 310 426 243 273 350              gold rank -
      (* = gold document; numbers are corpus document indices)

========================================================================
4. RE-COMPUTE METRICS FROM SCRATCH AND CHECK AGAINST results/main_results.csv
========================================================================
  query set  retriever     MRR@10    R@10  reported MRR@10  match
  rom        Dense-e5       0.143   0.294           0.143  OK
  rom_rules  Dense-e5       0.535   0.746           0.535  OK
  rom        BM25-char3     0.058   0.082           0.058  OK
  rom_rules  BM25-char3     0.684   0.812           0.684  OK
  en         Dense-e5       0.788   0.937           0.788  OK
  en         Hybrid-RRF     0.710   0.936           0.710  OK

Done.
```